

## 1. 熵的性质

离散熵的定义为

**定义 1.** 随机变量  $X \sim p(x), p(x_i) = p_i, i = 1, \dots, n, x_i \in \mathcal{X} = \{x_1, \dots, x_n\}$ ,

$$H(p_1, \dots, p_n) \triangleq - \sum_{i=1}^n p_i \log p_i = \mathbb{E}[\log p(X)]$$

其中  $\log$  以 2 为底, 熵的单位是比特。

熵函数的性质:

- 非负性
- 是  $n$  的增函数
- 可加性

$$H(p_1, p_2, \dots, p_n) = H\left(\sum_{i=1}^k p_i, p_{k+1}, \dots, p_n\right) + \sum_{i=1}^k p_i H(p'_1, \dots, p'_k)$$

其中  $p'_i = p_i / \sum_{i=1}^k p_i$

- 对称性, 若  $\sigma$  为  $1, \dots, n$  上的一个置换, 则:

$$H(p_1, \dots, p_n) = H(p_{\sigma(1)}, \dots, p_{\sigma(n)})$$

- 称  $h(p) \triangleq H(p, 1-p)$  为二元熵函数, 易证  $h(p)$  是上凸函数。一般地, 设  $\mathbf{P} = (p_1, \dots, p_n)$ , 所有长为  $n$  的概率向量  $\mathbf{P}$  组成一个凸域  $D$ 。利用  $-p \log p$  函数的上凸性可以证明  $\forall \mathbf{P}, \mathbf{P}' \in D$  有

$$H(\lambda \mathbf{P} + (1-\lambda) \mathbf{P}') \geq \lambda H(\mathbf{P}) + (1-\lambda) H(\mathbf{P}')$$

即  $H(\mathbf{P})$  是  $\mathbf{P}$  的上凸函数。

## 2. 联合熵和条件熵

**定义 2.** 一对离散型随机变量  $(X, Y)$ , 联合分布为  $p(x, y)$ , 它们的联合熵为

$$H(X, Y) \triangleq - \sum_{\substack{x \in \mathcal{X} \\ y \in \mathcal{Y}}} p(x, y) \log p(x, y) = -\mathbb{E}[\log p(X, Y)]$$

**定义 3.**  $Y$  对于  $X$  的条件熵定义为

$$\begin{aligned}
 H(Y|X) &\triangleq \mathbb{E}_X[H(Y|X=x)] \\
 &= \sum_{x \in \mathcal{X}} p(x) H(Y|X=x) \\
 &= \sum_{x \in \mathcal{X}} p(x) \left[ - \sum_{y \in \mathcal{Y}} p(y|X=x) \log p(y|X=x) \right] \\
 &= - \sum_{x \in \mathcal{X}, y \in \mathcal{Y}} p(x, y) \log p(y|X=x) \\
 &= - \mathbb{E}_{X,Y}[\log p(Y|X)]
 \end{aligned}$$

关系式:

$$\bullet H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

证明.

$$\begin{aligned}
 H(X, Y) &= - \sum_{x \in \mathcal{X}, y \in \mathcal{Y}} p(x, y) \log p(x, y) \\
 &= - \sum_{x \in \mathcal{X}, y \in \mathcal{Y}} [p(x, y) \log p(y|X=x) + p(x, y) \log p(x)] \\
 &= - \sum_{x \in \mathcal{X}, y \in \mathcal{Y}} p(x, y) \log p(y|X=x) - \sum_{x \in \mathcal{X}} p(x) \log p(x) \\
 &= H(Y|X) + H(X)
 \end{aligned}$$

□

$$\bullet \text{ 记 } H(X_1|X_0) = H(X_1), \text{ 则有}$$

$$H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i|X_1, \dots, X_{i-1})$$

### 3. 相对熵

**定义 4.** 设  $p(x), q(x)$  是  $\mathcal{X}$  中字母表相同的两个概率分布, 则它们的相对熵定义为:

$$D(p||q) \triangleq \sum_{x \in \mathcal{X}} p(x) \log \frac{p(x)}{q(x)} = \mathbb{E}_X \left[ \log \frac{p(X)}{q(X)} \right]$$

**定理 1.**  $D(p||q) \geq 0$ , 等号成立当且仅当  $p = q$

证明. 由  $-\log p$  函数的下凸性质,

$$\begin{aligned} D(p||q) &= \mathbb{E}_X \left[ -\log \frac{q(X)}{p(X)} \right], \text{ by Jensen's Inequality} \\ &\geq -\log \left( \mathbb{E}_X \left[ \frac{q(X)}{p(X)} \right] \right) \\ &= 0 \end{aligned}$$

由 Jensen 不等式的取等条件,  $\frac{p}{q}$  应为常数 □

利用相对熵的非负性, 我们可以证明

**推论 1.** 设  $X$  是在字母表  $\mathcal{X}$  上取值的随机变量, 则  $H(X) \leq \log |\mathcal{X}|$ , 等号成立当且仅当  $X$  是均匀分布。

证明. 设  $u$  是  $\mathcal{X}$  上的均匀分布, 则有  $D(X|u) \geq 0 \Rightarrow H(X) \leq \log |\mathcal{X}|$  □

相对熵  $D(p||q)$  的下凸性可以总结为以下三点:

- $q$  固定, 由  $t \log t$  的下凸性可以得到

$$D(\lambda p + (1 - \lambda)p' || q) \leq \lambda D(p || q) + (1 - \lambda) D(p' || q)$$

- $p$  固定, 由  $-\log t$  的下凸性可以得到

$$D(p || \lambda q + (1 - \lambda)q') \leq \lambda D(p || q) + (1 - \lambda) D(p || q')$$

- 二元凸性

$$D(\lambda p + (1 - \lambda)p' || \lambda q + (1 - \lambda)q') \leq \lambda D(p || q) + (1 - \lambda) D(p' || q')$$

证明. 由对数和不等式

$$\sum_{i=1}^n a_i \log \frac{a_i}{b_i} \geq \left( \sum_{i=1}^n a_i \right) \log \frac{\sum_{i=1}^n a_i}{\sum_{i=1}^n b_i} \quad (1)$$

$$\begin{aligned} D(\lambda p + (1 - \lambda)p' || \lambda q + (1 - \lambda)q') &= \sum_{x \in \mathcal{X}} (\lambda p(x) + (1 - \lambda)p'(x)) \log \frac{\lambda p(x) + (1 - \lambda)p'(x)}{\lambda q(x) + (1 - \lambda)q'(x)} \\ &\leq \sum_{x \in \mathcal{X}} \left[ \lambda p(x) \log \frac{p(x)}{q(x)} + (1 - \lambda)p'(x) \log \frac{p'(x)}{q'(x)} \right] \\ &= \lambda D(p || q) + (1 - \lambda) D(p' || q') \end{aligned}$$

□

## 4. 互信息

**定义 5.** 设  $(X, Y) \sim p(x, y), x \in \mathcal{X}, y \in \mathcal{Y}$ ,  $X, Y$  的互信息定义为

$$I(X; Y) \triangleq \sum_{\substack{x \in \mathcal{X} \\ y \in \mathcal{Y}}} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

互信息量有如下的性质:

- $I(X; Y) = D(p(x, y) || p(x)p(y)) \Rightarrow I(X, Y) \geq 0$  且  $I(X; Y) = 0 \iff p(x, y) = p(x)p(y)$
- $I(X; Y) = H(X) - H(X|Y) = H(Y) - H(Y|X) = H(X) + H(Y) - H(X, Y)$
- $I(X; Y|Z) = 0 \iff p(x, y|z) = p(x|z)p(y|z)$  ( $X, Y$  关于  $Z$  条件独立)  $\iff X \rightarrow Z \rightarrow Y$  构成马氏链
- 互信息的链式法则

$$I(X_1, \dots, X_n; Y) = \sum_{i=1}^n I(X_i; Y | X_1, \dots, X_{i-1})$$

证明.

$$\begin{aligned} I(X_1, \dots, X_n; Y) &= H(X_1, \dots, X_n) - H(X_1, \dots, X_n | Y) \\ &= \sum_{i=1}^n H(X_i | X_1, \dots, X_{i-1}) - \sum_{i=1}^n H(X_i | X_1, \dots, X_{i-1}, Y) \\ &= \sum_{i=1}^n I(X_i; Y | X_1, \dots, X_{i-1}) \end{aligned}$$

□

互信息  $I(X; Y)$  可以看成是  $p(x), p(y|x)$  的泛函数:

$$I(X; Y) = \sum_{\substack{x \in \mathcal{X} \\ y \in \mathcal{Y}}} p(x)p(y|x) \log \frac{p(y|x)}{\sum_{x \in \mathcal{X}} p(x)p(y|x)}$$

关于互信息的凸性可以总结为以下两点:

- $I(X; Y)$  关于  $p(x)$  上凸
- $I(X; Y)$  关于  $p(y|x)$  下凸。

数据处理不等式: 设  $P_Y = P_{Y|X} \circ P_X, Q_Y = P_{Y|X} \circ Q_X$  则  $D(P_X || Q_X) \geq D(P_Y || Q_Y)$ 。

证明.  $\mathbb{E}_{XY}[\log \frac{P_{XY}}{Q_{XY}}] = \mathbb{E}_{XY}[\log \frac{P_{Y|X}}{Q_{Y|X}} + \log \frac{P_X}{Q_X}]$  因为  $Q_{Y|X} = P_{Y|X} \Rightarrow \mathbb{E}_{XY}[\log \frac{P_{XY}}{Q_{XY}}] = D(P_X || Q_X)$  又

$$\begin{aligned} \mathbb{E}_{XY}[\log \frac{P_{XY}}{Q_{XY}}] &= \mathbb{E}_{XY}[\log \frac{P_{X|Y}}{Q_{X|Y}} + \log \frac{P_Y}{Q_Y}] \\ &= \mathbb{E}_Y[D(P_{X|Y} || Q_{X|Y})] + D(P_Y || Q_Y) \\ &\geq D(P_Y || Q_Y) \end{aligned}$$

所以有  $D(P_X || Q_X) \geq D(P_Y || Q_Y)$ 。  $\square$

5. 微分熵 设  $X$  是连续型随机变量,  $X$  的微分熵定义为:

$$h(X) \triangleq - \int_{\mathbb{R}} p(x) \log p(x) dx \quad (2)$$

$X^{(\Delta)}$  是  $X$  按区间长度为  $\Delta$  离散的结果。则  $H(X^{(\Delta)}) + \log \Delta \rightarrow h(X)$

微分熵可正可负

常见分布的微分熵

**命题 1.** (a) 区间  $(0, a)$  上的均匀分布的微分熵为  $\log a$ , 可正可负。

(b) 方差为  $\sigma^2$  的高斯分布微分熵的大小为  $\frac{1}{2} \log(2\pi e \sigma^2)$

(c) 均值为  $\frac{1}{\lambda}$  的指数分布的微分熵为  $\log e - \log \lambda$

证明. (a) 不妨设高斯分布  $X$  的均值为 0, 概率密度函数为  $p(x)$  则

$$\begin{aligned} h(X) &= - \int_{\mathbb{R}} p(x) \log \left( \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{x^2}{2\sigma^2}\right) \right) dx \\ &= \frac{1}{2} \log(2\pi\sigma^2) + \frac{\log e}{2\sigma^2} \int_{\mathbb{R}} x^2 p(x) dx \\ &= \frac{1}{2} \log(2\pi e \sigma^2) \end{aligned}$$

(b)

$$h(X) = - \int_0^\infty \lambda e^{-\lambda x} (\log \lambda - \lambda x \log e) dx = \log e - \log \lambda$$

$\square$

## 6. 相对熵和互信息（连续情形）

**定义 6.** 若  $X \sim p(x), Y \sim q(y)$  连续, 则  $X$  和  $Y$  的相对熵为

$$D(p||q) \triangleq \int_{\mathbb{R}} p(x) \log \frac{p(x)}{q(x)} dx \quad (3)$$

$X$  和  $Y$  的互信息为:  $I(X;Y) = D(p(x,y)||p(x)q(y))$

常见的连续型概率分布可以看成是某种条件下的最大熵分布:

**定理 2.** 对概率密度族  $\mathcal{P}$ , 若存在  $p_0(x) \in \mathcal{P}$ , 使得

$$\forall p(x) \in \mathcal{P}, - \int_{\mathbb{R}} p(x) \log p_0(x) dx = h_0$$

是一个与  $p(x)$  无关的常数, 则  $p_0(x)$  为最大熵分布,  $h_0$  为最大熵。

**证明.** 由相对熵的非负性得:

$$- \int_{\mathbb{R}} p(x) \log p(x) dx \leq - \int_{\mathbb{R}} p(x) \log p_0(x) dx = h_0$$

等号成立当且仅当  $p(x)$  与  $p_0(x)$  几乎处处相等。 □