

# 信号估值理论

赵丰

2018 年 6 月 6 日

## 1. Bayes 估值

代价函数  $C(\hat{\theta}, \theta) = C(\tilde{\theta})$ , 其中  $\tilde{\theta} = \hat{\theta} - \theta$ 。平均风险

$$\bar{R} = \int_{\mathcal{Z}} \int_{\Theta} C(\tilde{\theta}) d\theta dz$$

记  $\bar{R}(z) = \int_{\Theta} C(\tilde{\theta}) p(\theta|z) d\theta$ , 称为“给定  $z$  时的条件风险”。则  $\bar{R} = \int_{\mathcal{Z}} \bar{R}(z) p(z) dz$ 。Bayes 估值等价于求解  $\underset{\hat{\theta}}{\operatorname{argmin}} \bar{R}(z)$

## 2. 常见的代价函数

(1) 平方误差代价:  $C(\tilde{\theta}) = \tilde{\theta}^2$ ,  $\hat{\theta}_{\text{ms}} = \int_{\Theta} \theta p(\theta|z) d\theta = \mathbb{E}[\theta|z]$ ,  $\hat{\theta}_{\text{ms}}$  被称为后验均值。

(2) 绝对误差代价:  $C(\tilde{\theta}) = |\tilde{\theta}|$ ,  $\hat{\theta}_{\text{abs}}$  满足  $\int_{-\infty}^{\hat{\theta}_{\text{abs}}} p(\theta|z) d\theta = \int_{\hat{\theta}_{\text{abs}}}^{+\infty} p(\theta|z) d\theta$ ,  $\hat{\theta}_{\text{abs}}$  被称为后验中值。

(3) 均匀误差代价:

$$C(\tilde{\theta}) = \begin{cases} 0, & |\tilde{\theta}| \leq \frac{\Delta}{2} \\ 1, & |\tilde{\theta}| > \frac{\Delta}{2} \end{cases}$$

此时的条件风险为:

$$\bar{R}(z) = 1 - \int_{\hat{\theta} - \frac{\Delta}{2}}^{\hat{\theta} + \frac{\Delta}{2}} p(\theta|z) d\theta$$

当  $\Delta$  很小时, 使得条件风险  $\bar{R}(z)$  最小有:  $\hat{\theta}_{\text{unf}} \approx \hat{\theta}_{\text{map}}$ , 相当于后验概率密度的众数。

(4) 对称下凸代价

若代价函数满足

$$(a) C(\tilde{\theta}) = C(-\tilde{\theta})$$

$$(b) C(b\theta_1 + (1-b)\theta_2) \leq bC(\theta_1) + (1-b)C(\theta_2), \forall b \in (0, 1)$$

并且后验密度函数满足

$$(c) p(\theta|z) = p(2\hat{\theta}_{\text{ms}} - \theta|z)$$

$$\text{则 } \hat{\theta}_{\text{ms}} = \underset{\hat{\theta}}{\operatorname{argmin}} \bar{R}(z)$$

**证明.**

$$\bar{R}(z) = \int_{\mathbb{R}} C(\theta - \hat{\theta}) p(\theta|z) d\theta \quad (1)$$

$$\begin{aligned} &= \int_{\mathbb{R}} C(\theta - \hat{\theta}) p(2\hat{\theta}_{\text{ms}} - \theta|z) d\theta \\ &= \int_{\mathbb{R}} C(2\hat{\theta}_{\text{ms}} - \theta - \hat{\theta}) p(\theta|z) d\theta \\ &= \int_{\mathbb{R}} C(-2\hat{\theta}_{\text{ms}} + \theta + \hat{\theta}) p(\theta|z) d\theta \end{aligned} \quad (2)$$

对 (1) 和 (2) 作平均得:

$$\begin{aligned} \bar{R}(z) &= \int_{\mathbb{R}} \frac{1}{2} \left( C(\theta - \hat{\theta}) + C(-2\hat{\theta}_{\text{ms}} + \theta + \hat{\theta}) \right) p(\theta|z) d\theta \\ &\geq \int_{\mathbb{R}} C(\theta - \hat{\theta}_{\text{ms}}) p(\theta|z) d\theta \end{aligned}$$

上式右端和  $\hat{\theta}$  无关, 当  $\theta - \hat{\theta} = -2\hat{\theta}_{\text{ms}} + \theta + \hat{\theta}$  时不等式成立, 即  $\hat{\theta} = \hat{\theta}_{\text{ms}}$  □

(5) 对称非下凸代价

### 3. 常见估值方式

(a) 极大极小估值: 先验未知, 寻找先验概率  $p(\theta)$  的最不利分布, 再确定 Bayes 估值。

(b) 最大后验估值: 代价函数未知, 求解最大后验方程,

$$\left[ \frac{\partial \ln p(z|\theta)}{\partial \theta} + \frac{\partial p(\theta)}{\partial \theta} \right] \Big|_{\theta=\hat{\theta}_{\text{map}}} = 0 \quad (3)$$

(c) 最大似然估值: 先验和代价函数均未知  $\hat{\theta}_{\text{ML}} = \max_{\theta} p(z|\theta)$

### 4. 估计量的性质

(a) 无偏估计量

对于随机参量  $\theta$ , 无偏性要求  $\mathbb{E}[\hat{\theta}] = \mathbb{E}[\theta]$  即  $\int_{\Theta} \int_{\mathcal{Z}} \hat{\theta} p(z, \theta) dz d\theta = \int_{\mathcal{Z}} \hat{\theta} p(z) dz$

(b) 一致估计量

基于  $N$  个观测值组成的观测矢量  $\mathbf{z}_N$  作估值:  $\hat{\theta}(\mathbf{z}_N)$  是参数  $\theta$  的一致估计量, 当其满足

$$\lim_{N \rightarrow \infty} \Pr(|\hat{\theta}(\mathbf{z}_N) - \theta| < \epsilon) = 1, \forall \epsilon > 0$$

(c) 充分统计量:  $\hat{\theta}(z)$  是参数  $\theta$  的充分统计量, 当  $p(z|\theta) = p(\hat{\theta}(z)|\theta)h(z)$

(d) 有效 (efficient) 统计量: 具有最小方差的无偏估计量。

## 5. C-R 不等式

	非随机	随机
等价形式	$\mathbb{E}[(\hat{\theta} - \theta)^2   \theta] \geq 1 / \mathbb{E} \left[ \left( \frac{\partial \ln p(z \theta)}{\partial \theta} \right)^2   \theta \right]$ $\mathbb{E} \left[ \left( \frac{\partial \ln p(z \theta)}{\partial \theta} \right)^2   \theta \right] = -\mathbb{E} \left[ \frac{\partial^2 \ln p(z \theta)}{\partial \theta^2} \right]$	$\mathbb{E}[(\hat{\theta} - \theta)^2] \geq 1 / \mathbb{E} \left[ \left( \frac{\partial \ln p(z, \theta)}{\partial \theta} \right)^2 \right]$ $\mathbb{E} \left[ \left( \frac{\partial \ln p(z, \theta)}{\partial \theta} \right)^2 \right] = -\mathbb{E} \left[ \frac{\partial^2 \ln p(z, \theta)}{\partial \theta^2} \right]$
存在条件	$\frac{\partial p(z \theta)}{\partial \theta} = (\hat{\theta} - \theta) \cdot K(\theta)$	$\frac{\partial p(z, \theta)}{\partial \theta} = (\hat{\theta} - \theta) \cdot K$
有效估值存在	有效估值就是最大似然估值	有效估值就是 $\hat{\theta}_{\text{ms}}$ 或 $\hat{\theta}_{\text{map}}$

表 1: 随机参量和非随机参量的对比

在随机参量的情况下, 有  $\frac{\partial p(z, \theta)}{\partial \theta} = \frac{\partial p(\theta|z)}{\partial \theta}$ 。若有效估值存在, 则后验概率密度满足方程  $\frac{\partial p(z, \theta)}{\partial \theta} = (\hat{\theta} - \theta) \cdot K$ , 从而解出  $p(\theta|z) = D \exp \left( -\frac{K}{2} (\theta - \hat{\theta})^2 \right)$ , 即后验分布是高斯分布。反之, 若后验分布是高斯分布, 也满足有效估值存在性方程。所以对于随机参量, 有效估值存在当且仅当后验分布是高斯分布。

## 6. 白高斯信道中单参量信号的估值

假设观测信号  $z(t) = s(t, \theta) + n(t), 0 \leq t \leq T$

(1)  $\theta$  是未知的非随机参量时, 求  $\hat{\theta}_{\text{ML}}$

采用 K-L 展开求极限的方法,

将  $z(t)$  在归一化的正交基函数  $\{g_k(t)\}$  上作 K-L 展开:  $z(t) = \sum_{k=1}^{\infty} z_k g_k(t)$  其中,  $z_k = \int_0^T z(t) g_k(t) dt = \int_0^T [s(t, \theta) + n(t)] g_k(t) dt =$

$s_k(\theta) + n_k$  由于  $n_k$  为高斯分布, 故  $z_k$  亦为高斯分布, 且有

$$\begin{aligned}\mathbb{E}[z_k] &= s_k(\theta) \\ \text{Var}[z_k] &= \text{Var}[n_k] = \frac{N_0}{2} \\ \text{Cov}(z_k, z_l) &= \frac{N_0}{2} \delta_{kl}\end{aligned}$$

对观测矢量  $\mathbf{z}_N = (z_1, z_2, \dots, z_N)$  而言, 联合概率密度函数为:

$$p(\mathbf{z}|\theta) = \prod_{k=1}^N \frac{1}{\sqrt{2\pi N_0/2}} \exp\left(-\frac{(z_k - s_k(\theta))^2}{N_0}\right) = \left(\frac{1}{\sqrt{\pi N_0}}\right)^N \exp\left(-\frac{1}{N_0} \sum_{k=1}^N (z_k - s_k(\theta))^2\right)$$

因此  $\frac{\partial \ln p(\mathbf{z}_N|\theta)}{\partial \theta} = \frac{2}{N_0} \sum_{k=1}^N (z_k - s_k(\theta)) \frac{\partial s_k(\theta)}{\partial \theta}$  取极限得:

$$\frac{\partial p(z(t)|\theta)}{\partial \theta} = \lim_{N \rightarrow \infty} \frac{\partial \ln p(\mathbf{z}|\theta)}{\partial \theta} = \frac{2}{N_0} \sum_{k=1}^{\infty} (z_k - s_k(\theta)) \frac{\partial s_k(\theta)}{\partial \theta}$$

又根据  $z_k$  和  $s_k(\theta)$  的 K-L 展开式和公式  $\sum_{k=1}^{\infty} g_k(t)g_k(\tau) = \delta(t - \tau)$ , 我们有:

$$\begin{aligned}\sum_{k=1}^{\infty} z_k \frac{\partial s_k(\theta)}{\partial \theta} &= \sum_{k=1}^{\infty} \int_0^T \int_0^T z(t)g_k(t) \frac{\partial s(\tau, \theta)}{\partial \tau} g_k(\tau) dt d\tau \\ &= \int_0^T z(t) \frac{\partial s(t, \theta)}{\partial \theta} dt\end{aligned}$$

同理  $\sum_{k=1}^{\infty} s_k \frac{\partial s_k(\theta)}{\partial \theta} = \int_0^T s(t) \frac{\partial s(t, \theta)}{\partial \theta} dt$ , 从而有:

$$\frac{\partial p(z(t)|\theta)}{\partial \theta} = \frac{2}{N_0} \int_0^T (z(t) - s(t, \theta)) \frac{\partial s(t, \theta)}{\partial \theta} dt \quad (4)$$

由此可得最大似然方程:

$$\int_0^T (z(t) - s(t, \theta)) \frac{\partial s(t, \theta)}{\partial \theta} dt \Big|_{\theta=\hat{\theta}_{\text{ML}}} = 0 \quad (5)$$

对上式求导可得 C-R 界为  $\frac{N_0/2}{\int_0^T \left(\frac{\partial s(t, \theta)}{\partial \theta}\right)^2 dt}$

## (2) 信号幅度的估值

此时, 信号  $s(t, A) = As(t)$ , 其中  $A$  是待估值的非随机参量。

由(4)式等于 0 得到:

$$\hat{A}_{\text{ML}} = \frac{\int_0^T z(t)s(t)dt}{\int_0^T s^2(t)dt}$$

不妨令  $\int_0^T s^2(t)dt = 1$  (信号能量归一化), 易验证  $\hat{A}_{\text{ML}}$  具有性质:

(a) 无偏性

(b) 方差为  $\frac{N_0}{2}$ , 等于 C-R 界, 因此是有效估值。

(3) 信号相位的估值

此时, 信号  $s(t, \theta) = A \sin(\omega_0 t + \theta)$ ,  $0 \leq t \leq T$ , 其中  $\theta$  是待估值的非随机参量, 而  $A$  和  $\omega_0$  是已知常数, 假定  $\omega T$  是  $\pi$  的整数倍。由(4)式等于 0 得到:

$$\hat{\theta}_{\text{ML}} = \arctan \left( \frac{\int_0^T z(t) \cos \omega_0 t dt}{\int_0^T z(t) \sin \omega_0 t dt} \right)$$

当信噪比足够大时,  $n(t)/A$  是小量, 将上式中  $\arctan$  在  $\tan(\theta)$  处 Taylor 展开, 得到

$$\hat{\theta}_{\text{ML}} \approx \theta + \frac{2}{AT} \int_0^T \cos(\omega t + \theta) n(t) dt$$

因此  $\hat{\theta}_{\text{ML}}$  近似为均值为  $\theta$  (无偏), 方差为  $\frac{N_0}{A^2 T}$  (有效) 的高斯分布。

(4) 信号频率的估值

此时, 信号  $s(t, \omega) = A \sin(\omega t + \theta)$ ,  $0 \leq t \leq T$ , 其中  $\omega$  是待估值的非随机参量, 而  $A$  是已知常数,  $\theta$  是杂散参量。可以求出信号频率的最大似然估值为

$$\hat{\omega}_{\text{ML}} = \underset{\omega}{\text{argmin}} \left( \int_0^T z(t) \cos \omega t dt \right)^2 + \left( \int_0^T z(t) \sin \omega t dt \right)^2$$

(5)  $\theta$  为已知先验概率的随机参量时, 求  $\hat{\theta}_{\text{map}}$

首先, 我们通过最大后验方程(3)式来求其估值: 第一项已经由前面(4)求出, 最大后验方程可重写为

$$\left[ \frac{2}{N_0} \int_0^T (z(t) - s(t, \theta)) \frac{\partial s(t, \theta)}{\partial \theta} dt + \frac{\partial p(\theta)}{\partial \theta} \right] \Big|_{\theta=\hat{\theta}_{\text{map}}} = 0 \quad (6)$$

在 (2) 中, 若  $A \sim N(0, \sigma_A^2)$ , 根据(6) 可得信号的幅度估值为

$$\hat{A}_{\text{map}} = \frac{\int_0^T z(t) s(t) dt}{\int_0^T s^2(t) dt + \frac{N_0}{2\sigma_A^2}}$$

$\hat{A}_{\text{ML}}$  具有性质:

(a) 无偏性:  $\mathbb{E}[A] = 0, \mathbb{E}[\hat{A}_{\text{map}}] = 0$

(b) 利用随机参数的 C-R 界的公式,  $\mathbb{E}[(\hat{A}_{\text{map}} - A)^2]$  为  $1/[\frac{2}{N_0} \int_0^T s^2(t)dt + \frac{1}{\sigma_A^2}]$  等于 C-R 界, 因此是有效估值。

## 7. 色高斯信道非随机参量的估值

观测方程  $z(t) = s(t, \theta) + n(t), 0 \leq t \leq T$ , 其中  $n(t)$  为色高斯平稳噪声, 其相关函数记为  $R_n(t - \tau)$ 。沿用信号检测理论中的 K-L 展开法,  $z(t) = \sum_{k=1}^{\infty} z_k g_k(t)$ , 系数  $\{z_k\}$  互不相关, 且  $z_k \sim N(s_k, \lambda_k)$ 。似然函数为:

$$p(z(t)) = \prod_{k=1}^{\infty} \frac{1}{\sqrt{2\pi\lambda_k}} \exp\left(-\frac{(z_k - s_k)^2}{2\lambda_k}\right)$$

取其对数形式, 有:

$$\ln p(z(t)) = C - \sum_{k=1}^{\infty} \frac{z_k^2}{2\lambda_k} + \sum_{k=1}^{\infty} \frac{z_k s_k}{\lambda_k} - \sum_{k=1}^{\infty} \frac{s_k^2}{2\lambda_k} \quad (7)$$

其中  $C$  为与信号参量不相关的部分项。而在信号估计理论一节已经推导出

$$\sum_{k=1}^{\infty} \frac{z_k s_k}{\lambda_k} = \int_0^T z(t) h(t) dt \quad (8a)$$

$$\sum_{k=1}^{\infty} \frac{s_k^2}{2\lambda_k} = \frac{1}{2} \int_0^T s(t, \theta) h(t) dt \quad (8b)$$

其中  $h(t) = \sum_{k=1}^{\infty} \frac{s_k g_k(t)}{\lambda_k}$ , 为将  $h(t)$  表示成积分的形式, 引入反核函数  $R_n^{-1}(t - \tau)$ , 相对于  $R_n(t - \tau)$ , 我们有

$$R_n(t - \tau) = \sum_{k=1}^{\infty} \lambda_k g_k(t) g_k(\tau) \quad (9a)$$

$$R_n^{-1}(t - \tau) = \sum_{k=1}^{\infty} \frac{1}{\lambda_k} g_k(t) g_k(\tau) \quad (9b)$$

满足  $\int_0^T R_n^{-1}(t - \tau) R_n(\tau - \mu) d\tau = \delta(t - u)$  针对(9b), 两边乘以  $s(\tau, \theta)$  对  $\tau$  积分得:  $h(t) = \int_0^T s(\tau, \theta) R_n^{-1}(t - \tau) d\tau$  利用反核函数的表达式:

$$\begin{aligned} \sum_{k=1}^{\infty} \frac{z_k^2}{2\lambda_k} &= \frac{1}{2} \int_0^T \int_0^T z(t) z(\tau) \sum_{k=1}^{\infty} \frac{g_k(t) g_k(\tau)}{\lambda_k} dt d\tau \\ &= \frac{1}{2} \int_0^T \int_0^T z(t) z(\tau) R_n^{-1}(t, \tau) dt d\tau \end{aligned}$$

因此(7)化为：

$$\begin{aligned}
\ln p(z(t)) &= C - \frac{1}{2} \int_0^T \int_0^T [z(t)z(\tau) - 2z(t)s(\tau, \theta) + s(t, \theta)s(\tau, \theta)] R_n^{-1}(t - \tau) dt d\tau \\
&= C - \frac{1}{2} \int_0^T \int_0^T [z(t) - s(t, \theta)] R_n^{-1}(t - \tau) [z(\tau) - s(\tau, \theta)] dt d\tau \\
\frac{\partial \ln p(z(t)|\theta)}{\partial \theta} &= \int_0^T \int_0^T [z(t) - s(t, \theta)] R_n^{-1}(t - \tau) \frac{\partial s(\tau, \theta)}{\partial \theta} dt d\tau \\
&= \int_0^T (z(t) - s(t, \theta)) \frac{\partial h(t, \theta)}{\partial \theta} dt
\end{aligned}$$

利用极大似然法可以写出似然方程为

$$\int_0^T (z(t) - s(t, \theta)) \frac{\partial h(t, \theta)}{\partial \theta} dt \Big|_{\theta=\hat{\theta}_{\text{ML}}} = 0 \quad (10)$$

对比(5)式和(10)式可以发现, 色高斯信道的 ML 估计中求偏导用  $h(t, \theta)$  代替了  $s(t, \theta)$ 。当  $\lambda_k = \frac{N_0}{2}$  时,  $R_n(t - \tau) = \frac{N_0}{2} \delta(t - \tau)$ ,  $R_n^{-1}(t - \tau) = \frac{2}{N_0} \delta(t - \tau)$ ,  $h(t, \theta) = \frac{2}{N_0} s(t, \theta)$

另外不难求出估值的 C-R 界为  $1 / \int_0^T \frac{\partial s(t, \theta)}{\partial \theta} \frac{\partial h(t, \theta)}{\partial \theta} dt$

例：信号振幅估计  $s(t, A) = As(t)$ , 由(10)式解得：

$$\hat{A}_{\text{ML}} = \frac{\int_0^T z(t) \tilde{h}(t) dt}{\int_0^T s(t) \tilde{h}(t) dt}$$

其中  $\tilde{h}(t) = \int_0^T s(\tau) R_n^{-1}(t - \tau) d\tau$

8. 多参量估值：可由单参数估值形式推广

9. 线性最小均方估值

放宽对信号已知知识的要求，假设

(a) 对信号的统计知识只知道信号参量  $\theta$  和观测值  $z$  的一、二阶矩：

$$\mathbb{E}[\theta], \mathbb{E}[z], \text{Var}[\theta], \text{Var}[z], \text{Cov}[\theta, z]$$

(b) 估值是观测值的线性组合  $\hat{\theta} = \mathbf{A}z + \mathbf{b}$

MSE 估值准则为： $\min_{\mathbf{A}, \mathbf{b}} \mathbb{E}[(\hat{\theta} - \theta)^T (\hat{\theta} - \theta)]$ , 其中  $\mathbb{E}$  是关于  $\theta, z$  联合分布的期望。

首先说明最小均方估值是无偏的, 即  $\mathbb{E}[\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}] = \mathbf{0}$ , 反设  $\mathbb{E}[\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}] = \mathbf{b} \neq \mathbf{0}$  构造  $\hat{\boldsymbol{\theta}}' = \hat{\boldsymbol{\theta}} - \mathbf{b}$ , 有:

$$\begin{aligned}\mathbb{E}[(\hat{\boldsymbol{\theta}}' - \boldsymbol{\theta})^T(\hat{\boldsymbol{\theta}}' - \boldsymbol{\theta})] &= \mathbb{E}[(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})^T(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})] - \mathbf{b}^T \mathbf{b} \\ &< \mathbb{E}[(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})^T(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})]\end{aligned}$$

因此  $\mathbf{b} = \mathbb{E}[\boldsymbol{\theta}] - \mathbf{A}\mathbb{E}[\mathbf{z}]$  其次说明最小均方估值的误差与观测  $\mathbf{z}$  正交, 反设  $\mathbb{E}[(\hat{\boldsymbol{\theta}}_{\text{LMS}} - \boldsymbol{\theta})\mathbf{z}^T] = \boldsymbol{\Lambda}_{\mathbf{e}\mathbf{z}} \neq \mathbf{0}_{M \times N}$ , 其中  $\boldsymbol{\theta}$  是  $M$  维向量,  $\mathbf{z}$  是  $N$  维向量。构造  $\hat{\boldsymbol{\theta}}' = \hat{\boldsymbol{\theta}} - \boldsymbol{\Lambda}_{\mathbf{e}\mathbf{z}}\text{Var}^{-1}[\mathbf{z}](\mathbf{z} - \mathbb{E}[\mathbf{z}])$ , (不妨设  $M = 1$ , 否则分别考虑  $\boldsymbol{\theta}$  的各分量) 有:

$$\begin{aligned}\mathbb{E}[(\hat{\boldsymbol{\theta}}' - \boldsymbol{\theta})^T(\hat{\boldsymbol{\theta}}' - \boldsymbol{\theta})] &= \mathbb{E}[(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})^T(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})] - \boldsymbol{\Lambda}_{\mathbf{e}\mathbf{z}}\text{Var}^{-1}[\mathbf{z}]\boldsymbol{\Lambda}_{\mathbf{e}\mathbf{z}} \\ &< \mathbb{E}[(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})^T(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})]\end{aligned}$$

因此  $\hat{\boldsymbol{\theta}}_{\text{LMS}} - \boldsymbol{\theta}$  与  $\mathbf{z} - \mathbb{E}[\mathbf{z}]$  正交, 已有  $\hat{\boldsymbol{\theta}}_{\text{LMS}} = \mathbf{A}(\mathbf{z} - \mathbb{E}[\mathbf{z}]) + \mathbb{E}[\boldsymbol{\theta}]$ 。由  $\mathbb{E}[(\hat{\boldsymbol{\theta}}_{\text{LMS}} - \boldsymbol{\theta})(\mathbf{z} - \mathbb{E}[\mathbf{z}])^T] = \mathbf{0}$  得  $\mathbf{A} = \text{Cov}[\boldsymbol{\theta}, \mathbf{z}]\text{Var}^{-1}[\mathbf{z}]$  因此

$$\hat{\boldsymbol{\theta}}_{\text{LMS}} = \text{Cov}[\boldsymbol{\theta}, \mathbf{z}]\text{Var}^{-1}[\mathbf{z}](\mathbf{z} - \mathbb{E}[\mathbf{z}]) + \mathbb{E}[\boldsymbol{\theta}] \quad (11)$$

线性最小均方估值的误差矩阵为:

$$\begin{aligned}\text{Var}[\boldsymbol{\theta}_{\text{LMS}} - \boldsymbol{\theta}] &= \mathbb{E}[(\boldsymbol{\theta}_{\text{LMS}} - \boldsymbol{\theta})(\boldsymbol{\theta}_{\text{LMS}} - \boldsymbol{\theta})^T] \\ &= \text{Var}[\boldsymbol{\theta}] - \text{Cov}[\boldsymbol{\theta}, \mathbf{z}]\text{Var}^{-1}[\mathbf{z}]\text{Cov}[\mathbf{z}, \boldsymbol{\theta}]\end{aligned}$$

#### 10. 最小二乘估值: 仅有观测, 无先验

假定观测模型为:

$$\mathbf{z} = \mathbf{C}\boldsymbol{\theta} + \mathbf{n} \quad (12)$$

其中  $\mathbf{n}$  是观测噪声,  $\boldsymbol{\theta}$  是  $M$  维向量,  $\mathbf{z}$  是  $N$  维向量,  $N > M$ 。最小二乘估值准则为:

$$\min_{\hat{\boldsymbol{\theta}}=\hat{\boldsymbol{\theta}}_{\text{LS}}} (\mathbf{z} - \mathbf{C}\hat{\boldsymbol{\theta}})^T(\mathbf{z} - \mathbf{C}\hat{\boldsymbol{\theta}}) \quad (13)$$

解得

$$\hat{\boldsymbol{\theta}}_{\text{LS}} = (\mathbf{C}^T \mathbf{C})^{-1} \mathbf{C}^T \mathbf{z} \quad (14a)$$

$$= \boldsymbol{\theta} + (\mathbf{C}^T \mathbf{C})^{-1} \mathbf{C}^T \mathbf{n} \quad (14b)$$

因为  $\mathbb{E}[\mathbf{n}] = \mathbf{0}$ , 所以最小二乘估值对给定的观测模型是无偏估计。最小二乘估值的方差矩阵为

$$\text{Var}[\boldsymbol{\theta}_{\text{LS}} - \boldsymbol{\theta}] = (\mathbf{C}^T \mathbf{C})^{-1} \mathbf{C}^T \text{Var}[\mathbf{n}] \mathbf{C} (\mathbf{C}^T \mathbf{C})^{-1}$$



11. 加权最小二乘估值 (LSW) 对观测模型  $\mathbf{z} = \mathbf{C}\boldsymbol{\theta} + \mathbf{n}$  引入新的目标函数  $(\mathbf{z} - \mathbf{C}\boldsymbol{\theta})^T \mathbf{W}(\mathbf{z} - \mathbf{C}\boldsymbol{\theta})$ , 其中  $\mathbf{W}$  是对称正定的加权矩阵, 加权最小二乘估值准则可描述为:

$$\min_{\boldsymbol{\theta} = \boldsymbol{\theta}_{\text{LSW}}} (\mathbf{z} - \mathbf{C}\boldsymbol{\theta})^T \mathbf{W}(\mathbf{z} - \mathbf{C}\boldsymbol{\theta})$$

从而得到加权最小二乘估值为:  $\boldsymbol{\theta}_{\text{LSW}} = (\mathbf{C}^T \mathbf{W} \mathbf{C})^{-1} \mathbf{C}^T \mathbf{W} \mathbf{z}$  估值的方差矩阵为

$$\text{Var}[\boldsymbol{\theta}_{\text{LSW}} - \boldsymbol{\theta}] = (\mathbf{C}^T \mathbf{W} \mathbf{C})^{-1} \mathbf{C}^T \mathbf{W} \text{Var}[\mathbf{n}] \mathbf{W} \mathbf{C} (\mathbf{C}^T \mathbf{W} \mathbf{C})^{-1}$$

下面求方差矩阵的下限:

设  $\text{Var}[\mathbf{n}] = \mathbf{H}^T \mathbf{H}$ ,  $\mathbf{B} = \mathbf{H} \mathbf{W} \mathbf{C} (\mathbf{C}^T \mathbf{W} \mathbf{C})^{-1}$ , 则  $\text{Var}[\boldsymbol{\theta}_{\text{LSW}} - \boldsymbol{\theta}] = \mathbf{B}^T \mathbf{B}$ , 取  $\mathbf{A} = \mathbf{C}^T \mathbf{H}^{-1}$ , 则  $\mathbf{A} \mathbf{B} = \mathbf{I}$

使用矩阵不等式

$$\mathbf{B}^T \mathbf{B} \succcurlyeq (\mathbf{A} \mathbf{B})^T (\mathbf{A} \mathbf{A}^T)^{-1} (\mathbf{A} \mathbf{B}) \quad (15)$$

**证明.** 设  $\mathbf{x}$  是与  $\mathbf{B}$  的列数相同的列向量。只需证明  $\mathbf{x}^T \mathbf{B}^T \mathbf{B} \mathbf{x} \geq \mathbf{x}^T (\mathbf{A} \mathbf{B})^T (\mathbf{A} \mathbf{A}^T)^{-1} (\mathbf{A} \mathbf{B}) \mathbf{x}$ , 则只需证明  $\mathbf{I} - \mathbf{A}^T (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{A}$  半正定。设  $\mathbf{y}$  是  $\mathbf{A}^T (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{A}$  的特征向量, 特征值为  $\sigma$ , 则  $\mathbf{A}^T (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{A} \mathbf{y} = \sigma \mathbf{y}$ , 等式两端左乘以  $\mathbf{A} \Rightarrow \mathbf{A} \mathbf{y} = \sigma \mathbf{A} \mathbf{y}$ , 若  $\mathbf{A} \mathbf{y} \neq \mathbf{0} \Rightarrow \sigma = 1$ , 否则  $\sigma = 0$ , 因此  $\mathbf{A}^T (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{A}$  的特征值非 0 则 1, 半正定的结论成立。  $\square$

对于给定的下限问题, 由不等式(15)直接得到下限为  $(\mathbf{A} \mathbf{A}^T)^{-1}$ , 即

$$\text{Var}[\boldsymbol{\theta}_{\text{LSW}} - \boldsymbol{\theta}] \succcurlyeq (\mathbf{C}^T \text{Var}[\mathbf{n}] \mathbf{C})^{-1}$$

直接验证可得  $\mathbf{W} = \text{Var}^{-1}[\mathbf{n}]$  时取等号, 此时称  $\mathbf{W}$  为最佳加权矩阵。